

东方证券研究所面试课题 · WorkBuddy 专题研究

专题研究报告

从通用办公 Agent 到 Research Copilot

基于研究、事实核验、办公编辑与生态闭环的实测

作者：程浩然

日期：2026 年 8 月

摘要

本报告要回答一个具体的问题: 当研究型知识工作被交给通用办公 Agent, 哪些环节真正受益, 哪些环节反而添乱。我把 WorkBuddy、ChatGPT Work 与 TRAE Work 三款产品放进真实工作流里做对照: 先是开放式专题研究, 再做证据收口式的事实核验, 最后是直接修改办公文件; 随后对 WorkBuddy 的腾讯生态能力单独做了一层三层证据链测试, 从本地材料处理、真实连接器闭环, 一直测到与人工路径的摩擦对比。

结论有三条。第一, WorkBuddy 的能力上限不低: 办公文件编辑得分 92.10 居三家之首, 强模型配置下研究能力 91.25 分逼近 ChatGPT Work 的 92.81 分, ima 知识库实现了入库、检索、引用与摘要的全链路。第二, 它的表现高度依赖底层模型与配置: 默认配置下来源质量偏弱, 积分消耗波动明显, 事实核验环节必须有人工复核兜底。第三, 生态连接是真实的, 但价值按环节分化——知识库与文档读写环节确实省时间, PPT 加邮件的分发环节反而比人工更慢, 一次实测耗时约一小时、干预四次、邮件仍未发出。

我给出的定位判断是: WorkBuddy 现阶段是 **“带人工复核的研究与办公助手”**, 而不是可以无人值守的办公替身。它能承担材料消化、初稿生成、文件编辑与知识沉淀这类前期工作, 但口径判断、关键事实核验与对外交付仍需人工收口。这个判断贯穿全文, 也决定了后面对产品定位、商业化节奏与优化路线的讨论。

Contents

摘要 2

Contents 3

List of Figures 6

List of Tables 7

缩写表 8

1 研究背景与核心问题 9

1.1 研究出发点 9

1.2 分析框架 9

1.3 参照对象的选择 9

2 研究设计与证据边界 10

2.1 实验总体设计 10

2.2 研究假设 10

2.3 执行方式与评分原则 11

2.4 证据边界声明 11

3 三项测试的总体结果 12

4 测试一: 能力上限不低, 但默认配置不稳定 13

4.1 实验目的 13

4.2 资料、操作与评分 13

4.3 实验结果 13

4.4 换模型复测: 平台与模型的分离 14

4.5 本章判断 14

5 测试二: 会引用证据, 不等于结论正确 16

5.1 实验目的 16

5.2 资料与操作 16

- 5.3 Factcheck-GPT 子任务 16
- 5.4 FACTS Grounding 子任务 17
- 5.5 积分与质量: 一个被忽视的量化发现 17
- 5.6 本章判断 17
- 6 测试三: 办公文件是否真正改好 18**
 - 6.1 实验目的 18
 - 6.2 资料与操作 18
 - 6.3 实验结果 18
 - 6.4 本章判断 18
- 7 腾讯生态测试: 三层证据链的设计与验证 19**
 - 7.1 实验目的 19
 - 7.2 三层证据链的设计逻辑 19
 - 7.2.1 L1: 材料能力模拟 19
 - 7.2.2 L2: 真实工具闭环 19
 - 7.2.3 L3: 摩擦对比 19
- 8 L1: 材料理解能力成立, 口径仍需人工收口 20**
 - 8.1 HERB: 跨材料分析与增量修订 20
 - 8.2 MuDABench: 口径敏感问题的实证 20
- 9 L2: 知识库闭环是最扎实的正面结果 22**
 - 9.1 R1: 文档写回与平台偏差 22
 - 9.2 R2:ima 知识库全链路 22
 - 9.3 一个必须正视的静默错误 22
 - 9.4 本章小结 23
- 10 L3:PPT 与邮件分发环节的失败案例 24**
 - 10.1 R3: 一次完整的失败过程 24
 - 10.2 根因归属: 问题在工具链, 不在模型 24
 - 10.3 本章判断 24

11 成本与使用方式: 强模型应该配置在哪里 26

12 用户分层与付费判断 27

12.1 五类用户的实测画像 27

12.2 分场景的 ROI 测算 27

12.3 本章判断 28

13 从 WorkBuddy 到 Research Copilot: 优化路线 29

14 结论 30

14.1 已成立的优势 30

14.2 明确的不足 30

14.3 未来的整改方向 31

14.4 对研究问题的回答 31

14.5 假设验证汇总 32

14.6 局限性 33

参考文献 34

附录: 实验材料与数据说明 35

List of Figures

1	从产品能力到生态协同的分析路径	9
2	腾讯生态测试的三层证据链	10
3	三项测试的能力矩阵	12
4	测试一主测试结果	14
5	WorkBuddy 换模型复测结果	14
6	两类事实核验任务的主评分	17
7	HERB 四种模型组合的两阶段均分	20
8	MuDABench 六题得分	21
9	ima 知识库的解析覆盖情况	22
10	WorkBuddy 的后续优化顺序	29

List of Tables

1	三平台能力矩阵 (主评分)	12
2	测试一主测试: 维度得分与耗时	13
3	测试二: 两个子任务的主评分与资源消耗	16
4	分发环节的摩擦对比 (R3 实测 vs 人工估算)	24
5	模型路由建议	26
6	不同用户的价值判断	27

缩写表

AI	人工智能
LLM	大语言模型
Agent	智能体: 可自主调用工具、完成多步骤任务的程序
MAX	WorkBuddy 的高算力增强模式
HERB	腾讯混元推出的推理行为评测基准
MuDABench	中文企业多文档分析评测集 (本项目自建)
ima	腾讯 ima.copilot 智能工作台 (知识库)
KDocs	金山文档
ROI	投资回报率

1 研究背景与核心问题

1.1 研究出发点

研究型工作不是一个个孤立的问题，而是一条连续的问答链。以写一份行业研究报告为例：先要判断哪些资料可信、哪些来源值得引用；再逐项核对财务数字，把结论落进表格和正文；报告交出去之后，新材料、新版本、修改意见会不断进来，于是又要修订、又要更新口径、又要重新核对一遍。整个过程里，大部分时间其实花在“找、验、改”上，真正“写”的时间反而是少数。

正因为如此，单轮问答式的模型评测对这类工作几乎没有参考价值。模型能答得漂亮，不代表它能把一次开放式检索整理成可继续使用的底稿，更不代表它能记住上一版结论、在追加材料之后正确更新。我考察 WorkBuddy 的方式因此很直接：把它放进真实的研究流程里，看它在每一个环节是替人省时间，还是给人添麻烦。

1.2 分析框架

研究按五层递进展开：产品能力、真实工作流价值、可量化价值、付费意愿与生态放大效应。这五层不是并列关系，而是层层收紧：产品能力是必要不充分条件，只有通过了真实工作流检验的能力才有商业意义；可量化价值决定了用户愿不愿意付费；而生态是放大还是缩小这种价值的外部变量。产品与能力的官方说明见（腾讯，2026）。



Figure 1: 从产品能力到生态协同的分析路径

1.3 参照对象的选择

对照产品选了 ChatGPT Work 与 TRAE Work 两款。ChatGPT Work 是目前把研究做成品的流程最完整的代表，我用它考察“多步骤研究任务的稳定性”；TRAE Work 以速度和成本见长，我用它考察“效率维度”。早期考虑过的 Codex 更接近软件开发场景，Manus 未纳入核心实测，这两项调整都有明确的决策记录，并非遗漏。选择参照物本身也是研究设计的一部分：参照物决定了我能从差异中读出什么。

2 研究设计与证据边界

2.1 实验总体设计

研究由三项竞品测试与一组腾讯生态验证构成，四项实验分别对应工作链的一个环节：测试一考察“从公开资料形成研究交付”，对应链条的开头；测试二考察“把结论落回证据、在材料不支持时停止”，对应链条的核验环节；测试三考察“直接修改办公文件”，对应链条的交付环节。腾讯生态部分单独采用三层证据链，先做材料处理模拟，再做真实连接器闭环，最后与人工路径比较摩擦。



Figure 2: 腾讯生态测试的三层证据链

2.2 研究假设

研究不是“跑一遍看看结果”，而是先提出假设、再设计实验去验证或证伪。本研究的每一项实验都对应一个明确的假设：

- **H1 workflow假设:** 多步骤、跨文件任务的价值高于单轮问答。若成立，则 Agent 能完成真实的研究交付；若只有单轮问答强，则 Agent 对研究工作的价值有限。验证实验：测试一、测试三与生态测试的 R1/R2。
- **H2 连续性假设:** 核心价值在持续更新而非首次生成。研究工作的大头是“改”而不是“写”，Agent 能否在追加材料后正确更新旧结论，是它能否进入日常工作流的关键。验证实验：生态测试 R1 的增量修订、R2 的知识库版本区分。
- **H3 用户分层假设:** 技术用户从 Agent 获得的增量有限，非技术用户因低门槛获得明显价值。验证实验：生态测试的用户分层观察与 MuD-ABench 的人工复核需求。
- **H4 生态假设:** 生态连接只有在减少步骤、支持读写、支持远程触发时才有竞争优势；若只是“接入了很多系统”却增加步骤，则不构成优势。验证实验：生态测试 R1/R2(读写)、R3(分发) 与企微(远程触发)。
- **H5 商业化假设:** 个人用户为便利付费，企业用户为权限、知识库、安全与团队协作付费。验证实验：生态测试的 ROI 对比与企业用户观察。

- **H6 专业化假设:** 通用 Agent 能完成基础工作, 但垂直行业的 Research Copilot 需要行业模板、长期知识库、来源规范与跟踪机制。验证实验: MuDABench 的口径敏感问题。

六个假设不是孤立的: 它们从 “Agent 对单次任务有没有用”(H1) 递进到 “对长期工作有没有用”(H2)、 “对谁有用”(H3/H5)、 “生态放大还是缩小价值”(H4), 最后落在 “专业化是不是必经之路”(H6)。后面的每一章结论, 都会回到这六个假设上做一次对照。

2.3 执行方式与评分原则

这一节是整项研究的方法论基础, 四条规则保证了对比的公平与可复核。

第一, 冻结机制。任务包、提示词、输入材料、输出文件名与保存位置在正式运行之前冻结, 测试过程中不允许改动。这样做的原因很实际: Agent 类产品迭代快, 如果中途调整提示词或更换材料, 结果差异就无法归因——你分不清是平台能力差异, 还是任务定义变了。冻结之后, 任何改动都必须走版本变更记录, 相当于让三家在同一张卷子上答题。

第二, 交付物优先。评分先看交付物本身, 再看效率。不能打开的文件、无法核对的引用、没有写进文件的修改, 都不因文字自述得分。这条规则专门针对一个现象: Agent 很会 “说”, 把方案描述得头头是道, 但交付的文件打不开、公式是错的。只信交付物, 是这类评测最容易守住也最容易被忽视的一条底线。

第三, 同任务同输入。三家 Agent 接收同一版本的任务说明; 涉及文件的任务使用同一份输入文件——测试三用同一个 Excel 工作簿, 测试二用同一份唯一事实材料。输入不一致时得出的任何差异都没有意义。

第四, 运行记录。每次运行逐项记录时间、积分消耗、失败次数与人工干预次数。这些记录不直接参与质量评分, 却是后面分析成本可预测性、可靠性与摩擦的原始证据。

2.4 证据边界声明

需要诚实说明本设计的局限: 测试三只选了两道题; 企业微信受个人账号条件限制, 无法进入真实组织协作场景; 三家模型的配置无法完全对齐, ChatGPT Work 缺少同口径的积分数据。这些限制决定了结论的适用范围——本报告只针对本次固定任务与运行条件, 不把单次结果外推为平台的长期能力。承认边界, 是为了让结论经得起追问。

3 三项测试的总体结果

	测试一 研究	测试二 核验	测试三 办公编辑
WorkBuddy (HY3)	83.68	76.68	92.10
ChatGPT Work	92.81	74.99	65.05
TRAE Work	88.64	76.69	51.80

Figure 3: 三项测试的能力矩阵

Table 1: 三平台能力矩阵 (主评分)

任务	WorkBuddy	ChatGPT Work	TRAE Work
测试一 (研究)	83.68(HY3)	92.81	88.64
测试二 (核验, 平均主评分)	76.68	74.99	76.69
测试三 (办公编辑)	92.10	65.05	51.80

数据来源: 三项测试评分结果, 口径见第 2 章

先说明这张表的读法: 三列分数来自不同的评分口径——测试一按五个维度加权, 测试二是两个子任务的平均, 测试三是交付物核验。它们之间不能纵向相加, 这也是我没有把三家硬排成一个总分的原因。把口径不同的分数强行合并成一个名次, 看似简洁, 实际掩盖了每个平台在不同环节的真实强弱。

在各自的评分口径下, 三个横向判断值得注意。其一,ChatGPT Work 在研究任务中最稳, 是唯一在事实、完整性、观点、来源四个维度都没有明显短板的平台。其二,TRAE Work 的速度优势在测试一中非常突出, 总耗时只有 WorkBuddy 的三分之一左右, 但代价是研究完整性的短板。其三,WorkBuddy 的优势集中在办公编辑——92.10 分大幅领先, 这与其在测试一、二中的“中游偏上”位置形成鲜明对比, 说明它的能力不是均匀分布的, 评价它必须按场景拆开看。三个测试各自的原因, 在下面三章逐一展开。需要说明的是, 这三个测试共同回答了 H1(多步骤任务的价值): 三家都能完成多步骤交付, 但完成质量差异显著, 而生态测试的 R3 将证明“多步骤”本身并不自动等于“高价值”——这正是 H1 需要被精确化的地方。

4 测试一：能力上限不低，但默认配置不稳定

4.1 实验目的

这一测考察的不是“模型能列举多少事实”，而是“一次开放式检索能否被做成可继续使用的研究底稿”。合格结果的验收标准有三条：事实可回查、模型的迭代主线清晰、留下的是数据库、备忘录或汇报材料这类可复用产物，而不是一段读完就完的长回答。用这个标准的原因很简单：研究者的日常工作是在底稿上反复加工，而不是每次从零开始生成。

4.2 资料、操作与评分

三家 Agent 接收同一份专题研究提示词，自行检索公开资料并交付五类文件。WorkBuddy 的主测试使用混元 Hy3，随后用 Auto+MAX 与 DeepSeek V4 Flash+MAX 两种配置复跑，以区分“平台上限”与“模型配置”各自的影响。评分由四部分构成：任务输出本身、30 条分层事实抽样、12 个核心模型家族的检查表，以及每家 20 条引用的抽查。证据标准是严格的——一手来源只认官方公告、官方代码仓库、模型卡、原始论文与技术报告，媒体报道和聚合页可以作为线索，但不作为事实依据。这个标准直接决定了“来源与引用”维度的得分。

4.3 实验结果

Table 2: 测试一主测试：维度得分与耗时

平台	总分	事实	完整	观点	来源
ChatGPT Work	92.81	95.00	92.82	95.00	94.92
TRAE Work	88.64	93.33	81.89	82.50	95.75
WorkBuddy(HY3)	83.68	86.67	98.33	77.50	70.25

数据来源：测试一评分结果；总耗时：ChatGPT 约 449 秒、TRAE 约 285 秒、WorkBuddy 约 894 秒

如表 2 所示，主测试的结论是：ChatGPT Work 以 92.81 分居首，更重要的是四个维度都在高位，没有明显短板；TRAE Work 88.64 分，速度第一，但研究完整性只有 81.89，比第一名低了近 11 分；WorkBuddy(Hy3)83.68 分，研究完整性反而是三家最高的 98.33，说明它愿意也擅长铺开较宽的材料面，但来源与引用只有 70.25——抽样检查中一手来源比例偏低，较多依赖媒体报道、聚合页与第三方模型卡。这意味着它产出的参数、发布日期、定价与排名等信息，都需要更高强度的人工复核才能采用。




Figure 4: 测试一主测试结果

4.4 换模型复测：平台与模型的分离

主测试只能说明“默认配置下的 WorkBuddy”。为了分离平台与模型的影响, 我把同样的任务换到 Auto+MAX 与 DeepSeek V4 Flash+MAX 两种配置下重跑, 结果改变了对它的判断:Auto+MAX 得 91.25 分, 逼近 ChatGPT Work;DeepSeek V4 Flash+MAX 得 90.00 分, 耗时约 290 秒, 接近 TRAE Work 的速度水平。上下文消耗同样值得注意:DeepSeek 配置只用到 142.2k/1000k, 余量明显大于 Auto 配置的 150.5k/168.0k, 说明它在长任务中更“省”。




Figure 5: WorkBuddy 换模型复测结果

4.5 本章判断

我的判断是:WorkBuddy 的平台上限不低, 但用户实际获得的质量, 取决于底层模型、MAX 模式、上下文容量与工具链的组合。它不是一个“固定低分”的产品, 而是一个“能力高度依赖配置”的产品。对采购方来说, 这意味着只看产品入口是不够的——必须问清楚默认路由到哪个模型、上下文多大、MAX

模式怎么开、积分怎么消耗, 否则同一平台会表现出完全不同的质量与成本结构。

5 测试二：会引用证据，不等于结论正确

5.1 实验目的

事实核验考察的不只是“搜到链接”，而是三件更难的事：把一句声明拆解成可核验的原子事实、识别证据的边界在哪里、确认证据的位置是否真实存在。本测试还顺带观察一个问题：更长的回答、更多的积分消耗，是否真的带来更可靠的结论。

5.2 资料与操作

测试二由两个子任务构成。第一组采用 Factcheck-GPT 与 FactBench 共 12 题，覆盖可核验性判断、声明事实性与文档级核验 (Dong et al., 2023); 第二组采用 Google DeepMind 的 FACTS Grounding 公开样本 9 题，按短、中、长上下文各取三题 (Wei et al., 2025)。运行期间禁止联网，给定的唯一事实材料是答题依据。两个子任务考察的能力并不相同：前者暴露声明拆解与事实性判断，后者暴露上下文边界控制、证据定位与复杂指令遵循。

5.3 Factcheck-GPT 子任务

Table 3: 测试二：两个子任务的主评分与资源消耗

平台	Factcheck 主评分	FACTS 主评分	平均主评分	总耗时 (秒)	总积分
WorkBuddy	60.02	93.34	76.68	3622.80	498.70
ChatGPT Work	59.55	90.43	74.99	2499.75	未记录
TRAE Work	57.50	95.88	76.69	3292.65	413.31

数据来源：测试二评分结果;ChatGPT Work 未记录积分消耗

如表 3 所示，两个子任务放在一起看，没有一家在两个任务上同时领先:Factcheck 任务中 WorkBuddy 综合得分最高 (60.02),FACTS 任务中 TRAE Work 领先 (95.88),ChatGPT Work 则两项都居中。得分差异背后是能力结构的不同——WorkBuddy 强在文档级核验与声明事实性,ChatGPT Work 强在可核验性判断,TRAE Work 强在材料边界控制。此外，文档级任务预期拆出 60 条原子事实,ChatGPT 输出 27 条,WorkBuddy 输出 29 条,TRAE 输出 36 条：拆分数量最多并不自动等于质量最高，关键在于是否贴合标准事实单元，但 TRAE 更积极的拆分确实带来了更高的文档级核验得分。

5.4 FACTS Grounding 子任务

这一组 TRAE Work 表现最强, 主评分 95.88, 短中上下文任务的材料边界控制很好, 总耗时也最低; 风险在于长上下文任务中出现了不存在的段落编号, 这会直接降低人工复核的效率。WorkBuddy 93.34 分, 长上下文覆盖能力较强, 但同样存在证据映射问题, 比如部分段落编号错误、CSV 行错位。ChatGPT Work 90.43 分, 证据引用最为保守, 倾向于使用真实存在的段落编号, 降低了虚构证据位置的风险; 但它在 FACTS_004 中误读了题目里的关键约束, 在另一题中违反了“不得使用外部工具”的指令——它的短板不在输出结构, 而在复杂条件下的约束识别。




Figure 6: 两类事实核验任务的主评分

5.5 积分与质量: 一个被忽视的量化发现

把两个子任务的积分记录放在一起, 得到一个值得单独讨论的发现: WorkBuddy 的积分消耗波动明显大于 TRAE——单题积分从 4.47 到 54.97, 极差超过 12 倍, 变异系数约 67%; 而积分与质量的相关性接近零 (Factcheck 子任务中 WorkBuddy 为 -0.083, TRAE 为 -0.134)。也就是说, 多花积分并不带来更高的核验质量, 积分波动更可能反映的是任务路径、检索过程与平台内部资源调度的差异。这个发现的意义在于: 成本不可预测是 WorkBuddy 的真实短板, 而且它不能靠“多花钱买质量”来弥补。

5.6 本章判断

我的判断是: 事实核验类任务中不存在绝对领先的平台, 三家各有所长, 也各有失分点。WorkBuddy 质量均值略高、长材料覆盖较强, 但代价是积分消耗高且波动大; 它可以承担声明拆解、证据整理与不确定性暴露, 但关键数字、行业口径与对外结论必须由人确认——证据可复核, 不等于结论一定正确。

6 测试三：办公文件是否真正改好

6.1 实验目的

前两项测试都以 Markdown 交付, 容易让“会写说明”掩盖“未真正改文件”。办公编辑测试直接把考察对象换成文件本身: Agent 能否在理解现有工作簿、不破坏其他内容的前提下修复公式或创建图表, 并交回一份可继续使用的 Excel? 评分不再看描述, 而是直接检查输出文件能否打开、公式是否正确、图表对象是否真实存在。

6.2 资料与操作

资料取自 SpreadsheetBench 2 (Wu et al., 2024), 受时间限制选取两道题: 一道是财务模型的硬编码与公式修复, 一道是两月数据合并并生成折线图。三家使用同一份输入文件与固定的输出名, 交回后可被统一核验。

6.3 实验结果

第一题, WorkBuddy 与参考答案的一致率 99.53%、公式一致率 97.08%, ChatGPT Work 为 99.67% 与 97.77%——两家几乎打平, WorkBuddy 略低但高度接近; TRAE Work 的输出文件在这一题出现 XML 解析错误, 按评分规则视为无法可靠复核, 直接触发交付门槛。

第二题的差距被彻底拉开。WorkBuddy 与 TRAE 都检测到 1 个真实折线图、4 个系列、缺失值显示为空缺; 而 ChatGPT Work 的变更说明声称已经创建图表, 文件内部却没有真实的图表对象, 数据区还残留 150 个无效的等号公式。同样是“说做了”, 只有 WorkBuddy 和 TRAE 真正交出了可打开、可核验的图表文件。效率与成本方面, TRAE 最快 (约 446 秒), WorkBuddy 最慢 (约 1473 秒) 且两题消耗约 315 积分; WorkBuddy 第二题的上下文用到 117.3K/168K, 说明复杂办公任务会快速消耗上下文与额度。

6.4 本章判断

我的判断是: 办公 Agent 的分水岭不在“会不会分析任务”, 而在“能否稳定交付真实、可打开、可继续编辑的文件”。WorkBuddy 在这一项上综合最稳, 适合重交付、可复核的任务; ChatGPT Work 的公式审计很强, 但图表对象落盘不可靠; TRAE Work 极快且成本低, 但文件结构损坏风险让它存在高风险失效点。这也是 WorkBuddy 最接近日常办公价值的部分——前提是它愿意把速度与稳定性补上。

7 腾讯生态测试：三层证据链的设计与验证

7.1 实验目的

前三项测试说明的是单任务能力, 不能证明“腾讯生态”带来的增量。生态价值应该体现在软件之间: 资料进入文档云与知识库之后, 能否被继续读取、修改与引用; 研究成果能否再进入 PPT 与邮件。只有跑通整条链, 才能把模型能力、连接器能力与真实工作流的摩擦区分开来——这正是本模块与前三项测试的本质区别。

7.2 三层证据链的设计逻辑

7.2.1 L1: 材料能力模拟

第一层在本地完成, 材料是腾讯场景的典型形态 (项目文档、会议记录、沟通消息、PR 状态), 要求生成初版报告并做增量修订。这一层刻意排除网络与连接器干扰, 只回答一个问题: WorkBuddy 能不能消化这类材料、能不能在追加材料后正确更新结论。它证明材料处理能力, 但不证明生态价值。

7.2.2 L2: 真实工具闭环

第二层接入真实连接器, 做三条链路: R1 文档云创建、读回、修订、评论与分享; R2 ima 知识库的入库、检索、引用、摘要与版本修订; R3 从报告生成五页 PPT 并尝试通过邮箱发送。这一层回答的问题是: 生态连接能不能真实地读写、沉淀与分发。

7.2.3 L3: 摩擦对比

第三层把 R3 的真实执行与人工路径做摩擦对比, 比较耗时、人工介入次数与交付结果。这一层回答的是最实际的问题: 就算链路能跑通, 它比人自己动手是更快还是更慢? 值不值得用?

三层依次收紧: L1 排除干扰、L2 引入真实环境、L3 引入人工基线。任何一层单独存在都会得出偏颇的结论——只跑 L1 会高估生态, 只跑 L3 又无法定位问题出在模型还是连接器。

8 L1: 材料理解能力成立, 口径仍需人工收口

8.1 HERB: 跨材料分析与增量修订

HERB 材料包模拟了一个真实项目的多来源状态: 项目文档、会议记录、沟通消息与 PR 状态交织在一起, 信息互相印证也互相冲突。任务要求生成初版报告, 并在追加材料后完成增量修订。四组配置跑下来, DeepSeek V4 Flash 的初版与修订版均得满分; Hy3 得 96 分, 开启 MAX 后升至 98.5 分——它能识别产品方向变化、PR 状态与材料冲突, 并完成修订; 初版的小幅失分来自一处敏感性分析的漏检, 而 MAX 模式对此有明显补救作用。




Figure 7: HERB 四种模型组合的两阶段均分

HERB 还有一个细节值得单独说: 面对一个无法回答的问题, DeepSeek 正确选择了拒答, 而不是编造一个看似合理的答案。“知道什么时候该停下”是研究型任务的基本素养, 也是很多模型评测不会专门考、但真实工作里天天遇到的能力。

8.2 MuDABench: 口径敏感问题的实证

MuDABench 取六道中文企业多文档题, 最终只跑了 DeepSeek 一组。平均 71.50 分, 两道满分 (资本充足率前三、第一大股东前三), 四道出现口径分歧; 但六道题的证据可复核性全部满分——文件、页码、原文引用都极其扎实。失分不是来自事实错误或证据缺失, 而是来自“结论与锚点口径不一致”。

四处分歧逐一说明: 营业总成本一题, 锚点把银行也计入样本, 但银行利润表并没有“营业总成本”科目, 只有营业支出, 模型因此只统计了非银公司, 并明确标注了这层风险; 资本增长率一题, 锚点用的是资本充足率的变化率 (量级在 0.01%), 模型用的是更符合市场习惯的资本净额增速 (7%—10%); 异常公司判定一题, 模型的结论对均值的定义方式高度敏感, 剔除异常值前后结论完全不同; ESG 一题, 两份材料里没有股票代码, 模型按照“不得外部补全”的规则拒绝了这两家。这些分歧有一个共同点: 模型的逻辑在给定材料内自治,

出错的是“该用什么口径解读材料”这件事，而这恰恰是人需要介入的地方。




Figure 8: MuDABench 六题得分

我的判断是：模型并没有乱编，甚至主动暴露了不确定项，但“采用哪种业务口径”最终必须由人来决定。这正是“带人工复核闭环的研究助手”定位在能力层的最直接证据——它适合做研究，不适合无人值守的深度研究。

这个判断可以从三个层面展开。第一，失分的性质决定了问题的层级。六道题里证据可复核性全部满分，意味着模型的检索、定位与引用能力没有问题；失分全部集中在“结论与锚点口径不一致”，意味着问题不在“找不到事实”，而在“如何解读事实”。前者是执行层能力，后者是判断层能力，两层是分开的。

第二，模型在口径分歧中的行为是“可复核的坚持”。它在营业总成本一题里明确标注了“银行利润表没有该科目”的风险，在资本增长率一题里选择了更符合市场习惯的算法，在 ESG 一题里因材料缺失而拒绝作答——每一步都有明确的理由，不是随机出错。这恰恰是它适合与人工配合的原因：它会把自己的不确定暴露出来，人工只需要在这些暴露点上做裁决，而不是从头到尾复查。

第三，这组结果直接支持 H6 专业化假设。通用模型之所以在口径敏感题上失分，不是因为笨，而是因为它缺少“行业默认用什么口径”这类背景知识。一个面向金融行业的 Research Copilot，应该预置“营业总成本 vs 营业支出”“资本净额增速 vs 资本充足率变化”这类行业规则，让模型在解读材料时就有正确的默认值，而不是事后靠人工纠偏。这也是从“通用 Agent”走向“垂直行业 Agent”最具体的理由：MuDABench 的四道分歧题，就是行业模板必要性的四张成绩单。

9 L2: 知识库闭环是最扎实的正面结果

9.1 R1: 文档写回与平台偏差

R1 完成了文档云创建、写回、读回、增量修改、评论与分享的全链路, 判据 8 项全部达成, 但过程约 74 分钟, 效率明显偏低。更值得注意的是一个平台层面的发现: 这次实测实际调用的是金山文档 (KDocs), 而不是腾讯文档——连接器页面显示“已连接”, 并不保证对应的工具在会话中必然出现。因此 R1 只能作为“文档云闭环”的证据, 不能表述为“腾讯文档闭环”。这条观察本身就是研究的一部分: 连接器的信任度, 与工具实际暴露的确定性, 是两个不同的问题。

9.2 R2:ima 知识库全链路

R2 使用 ima 知识库完成了四步信息流:16 份 PDF 入库、网页导入、初版与修订版的增量管理、以及检索、引用与摘要。除建库这一步需要手动完成外, 链路基本走通, 全程约 20 分钟, 仅一次人工介入。对经常阅读大量报告的研究人员来说, 这项能力确实能省下反复翻文件的时间——16 份年报如果靠人逐份翻阅并定位数据, 通常需要数小时。



Figure 9: ima 知识库的解析覆盖情况

9.3 一个必须正视的静默错误

但 R2 也暴露了一个隐蔽的风险。步骤四检索“资本充足率前三”时, 模型给出建行、上海农商行、交行的排序, 与 L1 锚点 (工行、建行、农行) 不一致。排查后确认根因: 工行与农行的年报已经入库, 但当时异步解析尚未完成, 这两份材料根本没有进入对比范围。模型在回答中如实标注了“只比较了已解析文件”, 做法是负责的, 但结论在事实上仍然错了。

这个案例的价值在于它指出了知识库工具的一个结构性缺陷:** 入库成功、可

检索与结论完整是三件不同的事^{**}。入库成功只代表文件进了存储,可检索只代表解析已完成,而结论的完整性取决于全部相关材料是否都进入了推理。如果工具不展示解析覆盖率,用户就无法察觉结论是基于不完整样本得出的——这就是“静默缺样”。它再次印证了人工复核点的必要性:连“最顺滑可用”的知识库环节也逃不掉。

9.4 本章小结

L2 证明了生态的“数据层”与“执行层”是真实可用的:文档可以读写,知识库可以沉淀、检索并支撑创作。但可用性高度不均——知识库环节顺滑,文档环节低效,分发环节(见下一章)直接失败。生态连接是真实的,价值却必须按环节评估。

把三个任务的结论放在一起,可以提炼出四点。第一,链路完整性存在明显梯度:R2 是唯一“零摩擦”走完的闭环,从入库到检索到创作一气呵成;R1 链路虽通但耗时 74 分钟,效率上不具备日常可用性;R3 则直接失败。梯度不是随机分布,而是与“工具成熟度”正相关——知识库产品打磨最久,所以最顺;分发链路依赖最重的附件通道,所以最脆。

第二,R1 的平台偏差(kdocs 而非腾讯文档)揭示了一个被忽略的可靠性维度:“连接器显示已连接”不等于“工具在会话中必然可用”。对企业采购而言,这意味着必须用真实任务验证连接深度,而不能信任配置页面的状态;对评测而言,这意味着每个生态结论都要记录实际后端,否则会把平台 A 的能力记到平台 B 头上。

第三,静默错误是比显式失败更值得警惕的风险。R3 失败会立即暴露,用户马上知道要人工介入;R2 的错误则藏在“看似正常的结果”里——模型给出了排名,甚至标注了材料范围,但结论仍然是错的。知识库工具如果不提供解析覆盖率,这类错误就无法被用户察觉,这是生态产品在“可信度”上最需要补的一块。

第四,这组结果同时回应了 H2 与 H4 两个假设。H2 连续性假设得到验证:R1 的增量修订与 R2 的版本区分都成功完成,证明 Agent 能承载“持续维护”型工作,这正是研究工作的核心形态。H4 生态假设则被精确化:生态连接在“减少步骤”的环节(R2 检索替代翻文件)成立,在“增加步骤”的环节(R1 低效、R3 失败)不成立——生态价值不是整体的,而是分环节的,这为下一章的摩擦对比埋下了伏笔。

10 L3:PPT 与邮件分发环节的失败案例

10.1 R3: 一次完整的失败过程

R3 的意图是测通完整办公链路: 依据报告生成五页 PPT, 再通过 QQ 邮箱发送出去。结果这是一次教科书式的失败过程, 分三个阶段。第一阶段,PPT 生成的官方技能在本地运行时依赖装不上 (安装过程报错、依赖解析失败、原生依赖缺失), 折腾约十分钟后放弃, 换用替代方案; 第二阶段,PPT 最终生成成功, 但内容被反复压缩, 呈现质量完全不合格; 第三阶段, 邮件附件需要转成 base64, 文件过大导致工具调用多次无返回, 反复压缩 (从 1.6MB 压到 18KB) 仍然发不出去。

任务总共持续约一小时, 人工干预四次, 最终邮件未发出, 零交付。手工制作 PPT 并发送邮件, 估计只需要 10—20 分钟 (估算值, 非同条件实测)。差距超过三倍, 而且自动化路径没有任何产出, 结论已经不需要更多解释。

10.2 根因归属: 问题在工具链, 不在模型

这次失败最容易的归因是“模型不行”, 但细看记录会发现不是: 附件参数限制、技能依赖安装失败、工具调用超时——这些问题换更强的模型依然存在。更严重的是 Agent 缺乏止损机制: 依赖重试了四次、附件重试了三轮、工具调用无返回时仍沿着同一路径盲目重试, 直到用户干预。也就是说, 根因在平台工程层面, 而不是模型能力层面。这个区分很重要: 如果归因错误, 优化方向就会跟着错。

10.3 本章判断

Table 4: 分发环节的摩擦对比 (R3 实测 vs 人工估算)

指标	WorkBuddy(实测)	人工 (估算)
总耗时	约 60 分钟, 未完成	10—20 分钟, 完成
人工介入	4 次干预 + 1 次确认	0
完成状态	失败,0 交付	成功
失败与重试	附件重试 3 轮全部失败	通常没有

数据来源: 人工数据为估算区间, 仅用于量级对比

如表 4 所示, 我的判断是: 生态覆盖广与 workflow 好用是两回事, 这次失败把这条界限划得非常清楚。从表面看, 问题出在附件传输和技能依赖这些技术细节上, 但它们共同指向一个更深层的结论: 连接器的存在, 不等于连接器可用; 可用的定义, 不只是“能调用“, 而是“能在合理时间内稳定完成一件事“。

这个失败也修正了我对生态价值的理解。生态价值不是由连接器数量决定的,

而是由“它替用户省下了多少真实动作”决定的。R2 知识库之所以成立,是因为它把“翻开 16 份年报逐份找数据”压缩成了几次检索;R3 之所以失败,是因为它把“做 PPT 加发邮件”这件本来 10—20 分钟能做完的事,拖成了一个小时还没有结果。同样是生态连接,一个减摩擦,一个增摩擦,价值方向完全相反。因此,评估任何生态功能,都应该先问一句:它让用户少做了什么?而不是它接入了多少个系统。

对用户而言,现阶段让 Agent 独立完成“做 PPT 并发邮件”的任务,远不如自己动手。但这并不意味着生态路线本身有问题,而是说明分发环节的产品化程度还远未成熟——它需要工程层面先把附件通道、依赖预置和止损机制做好,才有资格谈“替代人工”。

11 成本与使用方式: 强模型应该配置在哪里

测试一告诉我们强模型能明显提升研究质量, 测试二告诉我们更多积分不一定提高核验得分。这两组证据看似矛盾, 其实指向同一个事实:WorkBuddy 的产出质量与资源消耗之间没有稳定的对应关系。质量取决于配置, 成本取决于路径, 两者是两条独立的曲线。把这两条曲线放在一起看, 一个合理的做法浮出水面: 不是全量开启 MAX, 而是按风险分级——把强模型花在最需要判断力的环节, 把便宜配置留给重复性工作。

成本结构本身也值得展开。测试二里,WorkBuddy 的积分变异系数约 67%, 单题积分从 4.47 到 54.97, 极差超过 12 倍;TRAE Work 的变异系数只有约 42%。也就是说, 在 WorkBuddy 上完成同一难度任务, 费用可以差出一个数量级, 而用户在下单前并不知道会落在哪一端。更麻烦的是, 积分与质量的相关性接近零 (Factcheck 子任务中 WorkBuddy 为 -0.083,TRAE 为 -0.134), 多花的积分并不带来更高的核验得分。对个人用户来说, 这意味着“贵”不等于“好“; 对企业来说, 这意味着预算无法被预测, 也就无法被管理。

上下文消耗是另一个被低估的成本维度。测试一中,DeepSeek 配置只用到 142.2k/1000k, 余量明显大于 Auto 配置的 150.5k/168.0k; 测试三第二题更是冲到 117.3K/168K。复杂办公任务会快速消耗上下文, 而上下文不足往往意味着任务中途降级或失败——这正是梯度路由需要提前感知的资源信号。

Table 5: 模型路由建议

任务阶段	建议配置	原因
整理与分类	混元 Hy3 或基础模型	任务重复, 错误易被后续发现
跨材料分析	DeepSeek 或强模型	需处理冲突与长上下文
正式交付前核验	强模型 + 人工复核	关键事实不能只靠模型自检

数据来源: 基于测试一、二结果的配置建议

但梯度控制有一个前提: 平台必须能提前告知大致成本, 并在上下文不足、连接器失败时给出明确反馈。如果做不到这一点, 梯度控制就只是用户个人的经验积累, 而不是稳定的产品能力。测试二里 67% 的积分变异系数, 正是这个前提缺失的量化证据——用户连“这单大概花多少”都猜不准, 自然不敢把重要任务交给它。更进一步说, 成本可预测性本身就是产品的一部分: 它决定用户敢不敢把高频任务交给 Agent, 也就决定了 Agent 能不能从“偶尔一用的玩具“变成“每天依赖的工具“。

12 用户分层与付费判断

12.1 五类用户的实测画像

个人用户最容易感知的价值是少翻文件、少做重复整理,ima 知识库正属于此类; 而 PPT 加邮件的失败体验, 则会直接抵消付费意愿。对熟悉编程的研究员来说,WorkBuddy 的增量价值有限——很多操作可以用脚本替代; 对不会编程的知识工作者, 它确实降低了使用门槛, 但要求用户具备基本的核验能力, 因为模型会给出看似确定、实际有误的答案。中小团队更看重共享知识库与用量管理; 大型企业则关注权限、安全、审计与企业微信入口——而这三项, 恰恰是本项目未能充分验证的部分。

Table 6: 不同用户的价值判断

用户类型	核心价值	付费判断
个人知识工作者	少翻文件、重复整理提效 (知识库)	标准版 ROI 为正; 分发场景为负
技术型研究员	增量价值有限, 可脚本替代	低, 倾向免费版或工具组合
非技术型研究员	低门槛 + 需复核闭环	中高, 标准/高级版
中小团队	共享知识库 + 用量管理	高, 企业版 (¥198/人/月)
大型企业	权限、安全、审计、企微入口	价值主张最强, 稳定性门槛高

数据来源: 基于本报告全部实测的用户价值判断

12.2 分场景的 ROI 测算

按研究员时薪约 150 元估算 (以月薪 2.5 万、月工时 170 小时折算), 知识库检索类任务单次净价值约 +240 至 530 元 (20 分钟 vs 人工 2—4 小时), 报告生成与修订类约 +300 至 740 元, 会议纪要类约 +80 至 240 元; 而 PPT 加分发场景是明确的负价值——约 -150 至 -220 元 (60 分钟失败 vs 人工 10—20 分钟完成)。也就是说, 一个每月做十次以上检索类任务的个人用户, 标准版 (连续包月 70 元) 的 ROI 显著为正; 而主要依赖分发场景的用户, 基本不会付费。

企业侧的账更清楚:SaaS 版约 198 元/人/月, 一个十人团队月成本约 1980 元, 需要每个成员每月稳定节省两小时以上的工作时间才能覆盖——在当前的稳定性水平下, 这个条件很难满足。价值主张最强的其实是大型企业 (权限、安全、审计、生态整合), 但恰恰是它们对稳定性要求最高, 而稳定性正是当前短板。

12.3 本章判断

综合上述测算, 我对 WorkBuddy 的用户分层与付费前景做出以下判断。

第一, 个人市场的付费逻辑是“省时间换订阅”, 且只在特定环节成立。个人用户愿意为知识库检索这类任务付费, 是因为单次净价值为正、且发生频率高——每月十次以上检索就能覆盖标准版月费。但同一个用户的付费意愿可以被一次失败的分发体验直接摧毁: 当用户意识到“交给它反而更慢”时, 前面积累的信任会整体归零。因此个人市场的关键是保证正价值场景的高可用, 而不是追求场景覆盖的广度。

第二, 企业市场的机会与门槛同样清晰。中小团队的核心诉求是共享知识库与用量管理, 这些是 WorkBuddy 已经具备的能力, 且定价 (约 198 元/人/月) 在可接受区间; 大型企业的价值主张最强——权限、安全、审计与企业微信入口都是中小企业给不了的差异化, 但恰恰是这三项本项目未能验证, 也是稳定性要求最高的部分。企业市场能不能起量, 取决于平台工程修复的进度, 而不是销售力度。

第三, 也是最重要的一点: 现阶段把 WorkBuddy 定义为“统一办公入口”为时过早。入口层的企业微信个人用户根本够不到, 数据层与执行层虽通, 分发层又不可用, 三条链路里只有知识库一条是完整闭环。一个还没有跑通一半链路的产品, 贸然以“入口”自居, 只会放大用户对缺失环节的期待, 然后以失望收场。更稳妥的商业化路径, 是从一个能打的场景 (知识库与检索) 出发, 把单点体验打磨到无感, 再逐步扩展到文档修订、纪要整理, 最后在稳定性达标后进入企业市场。这个顺序与“草房子先装修再出租”是同一个逻辑: 先证明能住人, 再谈当办公楼。

13 从 WorkBuddy 到 Research Copilot: 优化路线

做完实验, 我不再把 Research Copilot 理解为“更聪明的聊天窗口”, 而是一套完整的工作流: 知道哪些文件没有解析、何时应该停下来问人、记住研究口径与来源范围、维护观点的版本。这条路线不是凭空设计的, 每一步都对应一个实测缺陷。




Figure 10: WorkBuddy 的后续优化顺序

第一步 (短期) 解决失控问题。失败止损机制, 对应 R3 里依赖重试四次、附件重试三轮却仍沿原路径走下去的问题; 参数体量预检, 对应附件过大导致工具调用无返回的问题; 常用技能依赖预置, 对应 PPT 生成技能装不上的问题。这三个根因, 正好覆盖了本轮失败的主要直接原因。

第二步 (中期) 提升结果可信度。展示知识库解析覆盖率, 对应 R2 的静默缺样——用户需要知道结论基于多少材料; 优先发送链接而非硬塞附件, 绕开 base64 附件通道的硬阻塞; 把人工确认集中在高风险节点, 而不是让用户全程盯守。这一步的目标是把“需要复核”从被动救火变成主动设计。

第三步 (长期) 才是行业化。固定字段、来源白名单、口径模板与观点版本管理, 对应 MuDABench 的四题口径分歧——通用模型之所以在这些题上失分, 是因为缺少行业化的判定规则。到这一步, 产品形态就接近真正的垂直行业 Research Copilot 了。

支撑这条路线的是一个护城河判断: 模型可以被替换 (本项目全程使用外部模型, 平台本身没有模型壁垒), 连接器目前又不够稳定, 那么真正能沉淀下来的, 只有知识库数据、行业模板与长期工作记录这三样东西。它们都依赖长期使用积累, 因此时间窗口既是 WorkBuddy 的护城河建造期, 也是被竞品追赶的窗口期。

如果用一句话总结现状, 就是之前说的“草房子”: 能住, 说明方向正确; 漏风、工具不好用、线路不稳, 也都是真实存在的问题。当前最重要的不是继续增加房间, 而是把常用链路修好——装修工程量, 直接决定商业化能走到哪一步。

14 结论

14.1 已成立的优势

四项优势都有实测数据支撑，它们共同回答了“WorkBuddy 为什么值得关注”。

一是材料消化与证据定位能力强。HERB 两阶段满分，初版报告与追加材料后的修订全部正确，还能在材料不足时正确拒答；MuDABench 的证据可复核性六题全满分，文件、页码、原文引用都经得起回查。这意味着在“把多来源材料整理成可追溯的结论”这个研究最基础的动作上，它的能力是稳定可靠的。

二是办公文件编辑能力领先。测试三 92.10 分，大幅领先第二名 (65.05 分)，能真实修复 36 处公式问题并生成可打开的图表对象，而不是只交一份修改说明。这是三家中唯一在“交付真实、可打开、可继续编辑的文件”维度上表现稳定的平台，也是它最接近日常办公价值的部分。

三是知识库闭环可用。ima 实现入库、检索、引用与摘要的全链路，16 份 PDF 的处理替代了人工数小时的翻阅——这是腾讯生态里唯一被完整验证的正价值环节，也是“生态能沉淀知识”的直接证据。

四是强模型配置下研究能力接近第一梯队。Auto+MAX 复测 91.25 分，逼近 ChatGPT Work 的 92.81 分；DeepSeek V4 Flash+MAX 得 90.00 分且速度接近 TRAE Work。这说明平台的工程与工具链本身不是瓶颈，只要配置到位，它的上限不输给任何对手。

14.2 明确的不足

五项不足同样有据可查，它们共同决定了 WorkBuddy 目前只能做“助手”而不能做“替身”。

一是模型配置敏感。Hy3 基线下来源与引用维度只有 70.25 分，换到 Auto+MAX 后整体升到 91.25 分——同一平台、同一任务，质量可以相差近 8 分。用户的实际体验完全取决于默认路由到了哪个模型，而这种路由对用户是黑箱。

二是成本不可预测。积分变异系数约 67%，单题积分从 4.47 到 54.97，且积分与质量相关性接近零。用户既无法预估单次账单，也无法靠多花钱买到更可靠的结果，成本成为了一笔无法管理的支出。

三是连接器与技能稳定性不足。通道崩溃、依赖装不上、附件传输硬阻塞，均属平台工程问题，与模型无关——换更强的模型，这些问题一个都不会消失。生态覆盖面广是优势，但稳定性不均正在抵消这个优势。

四是 Agent 缺乏止损与反思机制。一次失败的任务需要用户四次干预,Agent 会沿着同一条失败路径反复重试,直到用户强制打断。这意味着“全程盯守”是当前使用 WorkBuddy 的隐性成本,也直接否定了“无人值守”的可能。

五是知识库存在静默缺样风险。入库不等于解析完整,工行与农行的年报缺席直接导致了一次错误的排名结论,而用户如果不逐份核对根本无从察觉。这个风险比显式的错误更危险,因为它不会报错。

14.3 未来的整改方向

整改方向不是一份愿望清单,而是把每个实测缺陷映射到对应工程动作之后得到的优先级顺序。

短期优先修复三个根因,直接消除本轮失败的主要来源:一是建立失败止损机制,让 Agent 在连续重试无果时改变策略或停下来询问,而不是反复撞同一堵墙;二是增加参数体量预检,在调用附件等通道前先判断负载是否可行,从源头避免工具超时;三是预置常用技能依赖,把 PPT 生成这类高频技能的运行环境提前装好,避免运行时现场安装失败。这三项都是平台工程动作,不依赖模型升级,投入产出比最高。

中期做好三件事,把“需要复核”从被动救火变成主动设计:展示知识库解析覆盖率,让用户一眼看到结论基于多少材料;优先发送链接而非硬塞附件,绕开附件通道的硬阻塞;将人工确认集中在高风险节点,而不是让用户全程盯守。

长期才谈行业化:固定字段、来源白名单、口径模板与观点版本管理,对应 MuDABench 的四题口径分歧——通用模型之所以在这些题上失分,是因为缺少行业化的判定规则。到这一步,产品形态就接近真正的垂直行业 Research Copilot,这也是本项目认为最值得期待的终局形态。

14.4 对研究问题的回答

回到开头的五层框架,每一层都得到了实证回答。

产品能力层面:WorkBuddy 的平台上限不低,换强模型后研究能力接近第一梯队,但默认配置拖累了实际体验——能力是存在的,问题在于如何被配置。

真实工作流层面:它在材料消化、文件编辑与知识沉淀三个环节创造了价值,在分发环节制造了摩擦。价值与摩擦并存,而非一边倒,这比“有没有用”的二元判断更接近真相。

可量化价值层面:检索与知识库场景的 ROI 为正(单次 +240 至 530 元),分发场景为负(单次 -150 至 -220 元)。省时间与费时间的分界非常清晰,而且可

以量化。

付费意愿层面: 个人用户只在检索类场景愿意付费, 企业用户价值主张最强但被稳定性挡在门外。付费意愿的分布与可量化价值的分布高度一致, 这本身说明用户的决策是理性的。

生态放大层面: 生态连接是真实的, 但价值必须按环节评估——知识库环节放大了价值, 分发环节反而缩小了价值。这是本项目对“生态假设”最重要的修正: 生态不是一个整体变量, 而是分环节变量; 评估它, 必须拆到每个具体工作流去看。

14.5 假设验证汇总

第 2 章提出的六个假设, 到这里可以逐一给出结论。它们不是装饰, 而是整项研究的问题骨架——每一条都有对应的实验证据, 或证实、或证伪、或被精确化。

H1 workflow假设 (部分成立)。多步骤任务确实能产出交付物: 测试一、测试三与 R1/R2 都完成了多步骤闭环。但 R3 证明多步骤不等于高价值——60 分钟、四次干预、零交付。价值上限成立, 可靠性不足, 这是 H1 被现实划出的边界。

H2 连续性假设 (成立, 验证最充分)。R1 的增量修订、R2 的知识库版本区分都成功完成, 证明 Agent 能承载“持续维护”型工作。研究工作的核心价值在更新而非首写, H2 是整个研究里被验证最扎实的假设, 也直接支撑了 Research Copilot 的构想。

H3 用户分层假设 (成立)。个人用户只触达数据层 (R2 正 ROI), 企微入口层个人不可达、天然属于企业; MuDABench 的复核需求印证非技术用户需要复核闭环。用户差异不是营销话术, 而是连接深度的客观结果。

H4 生态假设 (部分成立, 需精确化)。减步骤的环节成立 (ima 检索替代翻 16 份 PDF), 读写环节成立 (R1/R2); 但远程触发个人不可达 (企微), 分发环节反而增步骤 (R3)。结论: 生态价值按环节分化, 不能整体断言。

H5 商业化假设 (成立)。个人为便利付费 (R2 正 ROI), 企业为权限、知识库、安全付费 (企微企业专属), 付费意愿与实测价值的分布高度一致。

H6 专业化假设 (强成立)。MuDABench 四题口径分歧证明: 通用模型缺行业模板就会失分, 垂直行业 Research Copilot 需要口径预设与来源规范。这是整个研究指向最明确的结论, 也是优化路线第三步的依据。

六个假设全部得到了实证回应: 两个强成立 (H2/H6), 两个成立 (H3/H5), 两个部分成立需精确化 (H1/H4)。没有假设被证伪到推翻的程度, 但边界条件被清晰划出——这本身是本研究最有价值的修正。

14.6 局限性

最后需要再次声明本研究的局限，它们共同划定了结论的适用范围。

其一，测试三仅两题，办公编辑的结论基于有限样本，置信度低于其他两项测试；其二，R1 实际后端为金山文档而非腾讯文档，因此“腾讯文档闭环”未被直接验证，只能以“文档云闭环”表述，平台差异的结论有待在腾讯文档环境下复测；其三，L3 的人工耗时为估算区间而非同条件实测，摩擦对比仅用于量级判断，不构成精确测量；其四，企业微信与企业权限未在真实组织环境下测试，入口层与协作层的结论仍是空白；其五，WorkBuddy 的换模型复测未覆盖全部任务，配置敏感性的结论主要建立在测试一上。

后续研究应优先重复知识库与分发两个环节——前者是唯一完整的正价值闭环，需要更多样本确认其稳定性；后者是最大的负价值环节，需要在工程修复后验证改善程度。同时应在企业账号环境下补做入口层与协作测试，补齐生态验证的最后一块拼图。承认这些边界，与坚持前面的结论同样重要：它们不是报告的瑕疵，而是证据纪律的一部分，让每一个结论都明确标注了自己的适用范围。

参考文献

- Xinyan Dong, Jonathan Wang, Jackie Wu, Yichuan Sun, Vincent Choi, Faizan Khan, Ryo Kamoi, Xiaoxin Hu, Fangyuan Xu, and Hao Zhu. Factcheck-gpt: End-to-end fine-grained document-level fact-checking and correction of llm output. *arXiv preprint arXiv:2311.09000*, 2023.
- Jerry Wei, Chengrun Wei, Yi Tay, Dustin Tran, Dan Nemirovsky, Kayo Garcia, Hannah Eichner, Yifeng Hu, Xavier Savarese, Jie Zhou, et al. Facts grounding: A new benchmark for grounding llm responses to long-form documents. *arXiv preprint arXiv:2503.00293*, 2025.
- Zeyao Wu, Zilong Zhao, Yushuo Zhang, Ming Gong Li, Yongqiang Sun, Ye Bai, Guoliang Li, and Yuanzhe Wang. Spreadsheetbench: Towards challenging real world spreadsheet manipulation. *arXiv preprint arXiv:2410.13967*, 2024.
- 腾讯. Workbuddy 官方文档. <https://www.workbuddy.cn/docs/workbuddy/Overview>, 2026. 产品能力、连接器与技能体系的官方说明.

附录：实验材料与数据说明

A.1 材料存放

本项目全部实验材料、任务包冻结说明、评分锚点与原始输出, 按模块存放在项目仓库的对应目录中; 腾讯生态部分按能力层、真实闭环层与摩擦对比层三级组织。所有任务包在执行前冻结, 版本变更均有记录。

A.2 主要数据来源

测试一使用公开检索资料, 评分含 30 条分层事实抽样、12 个核心模型家族检查表与每家 20 条引用抽查; 测试二使用 Factcheck-GPT、FactBench 与 FACTS Grounding 公开样本; 测试三使用 SpreadsheetBench 2 样本; 腾讯生态测试使用 HERB 材料包与本项目自建的 MuDABench 中文企业资料库。各基准的原始引用见参考文献。

A.3 评分标准速查

测试一按五个维度加权 (事实可靠性、研究完整性、分析观点、来源与引用、效率); 测试二按两个子任务分别评分后取平均; 测试三直接核验交付文件 (可打开性、公式正确性、图表对象真实性); 腾讯生态部分按各任务的通过判据核验, 通过率等于通过项数除以适用项数。